

金融影像智能相似度检测 — 数据集说明

一、数据集概述

本数据集用于"基于多模态大模型的金融影像智能相似度检测模型"课题研究。数据集模拟银行信贷业务场景，包含 74 笔贷款业务的全套影像资料，其中部分业务存在面签照片被重复使用的可疑情况，供参赛团队训练和验证检测模型。

二、数据规模

指标	数值
贷款业务笔数	74 笔
总影像数量	370 张
影像类型	5 种
相似组数量	15 组
涉及相似对的影像	39 张

三、目录结构

loan_001/

face_signing.jpg

id_card_front.jpg

id_card_back.jpg

contract.jpg

bank_statement.jpg

loan_002/

...

...

loan_074/

...

annotations.csv

客户经理与客户面签合影

客户身份证正面

客户身份证反面

借款合同

银行交易流水

标注文件

每笔贷款业务对应一个文件夹，包含 5 张影像。同一笔业务内的身份证、合同、流水上的客户信息（姓名、证件号、地址）保持一致。

四、影像类型

类型标识	文件名	说明
face_signing	face_signing.jpg	客户经理上门面签时与客户的合影照片
id_card_front	id_card_front.jpg	客户身份证正面（含姓名、地址、证件号）
id_card_back	id_card_back.jpg	客户身份证反面（含签发机关、有效期）
contract	contract.jpg	个人借款合同（含甲乙双方信息、条款）
bank_statement	bank_statement.jpg	客户银行交易流水明细

五、标注文件（`annotations.csv`）

CSV 文件包含所有影像的元数据和相似对标注，字段如下：

字段	类型	说明	示例
image_id	string	影像唯一标识	IMG_00001
file_path	string	影像相对路径	loan_001/face_signing.jpg
image_type	string	影像类型	face_signing
business_type	string	贷款业务类型	商户易贷
loan_id	string	贷款业务编号	LN2024000001
similar_group	string	相似组ID（空值表示无相...	SG_001
is_similar_pair	int	是否为相似对成员（1=是，0=否）	1

六、相似对说明

数据集中存在 15 组面签照片相似对，模拟客户经理将同一张面签照片重复使用到不同客户贷款申请中的场景。

具体表现为：不同贷款业务（不同客户姓名、证件号、地址）的面签照片高度相似，但并非完全相同（存在轻微旋转、亮度差异、裁剪、缩放等变化）。

标注文件中 `similar_group` 字段相同的面签照片属于同一相似组，即为需要检测出的"可疑重复使用"。

七、任务目标

1. **面签照片识别**：从全部 370 张影像中准确筛选出 `face_signing` 类型的图片
2. **相似度检测**：在面签照片中检测出相似组，找出被重复使用的可疑照片对

八、数据说明

本数据集为合成数据，所有个人信息均为虚构，不涉及真实客户隐私。